

ESTADISTICA

1. MODELOS PROBABILÍSTICOS DISCRETOS

PROBABILIDAD EMPIRICA: cociente entre si un acontecimiento ocurre o no y el número de repeticiones del experimento observado

$$P(A) = \frac{n(A)}{n}$$

3 propiedades: $0 \leq n(A) \leq n \rightarrow 0 \leq P(A) \leq 1$

$$n(A) = n \rightarrow P(A) = 1$$

$$n(A \cup B) = n(A) + n(B) \rightarrow P(A \cup B) = P(A) + P(B)$$

EXPERIMENTO ALEATORIO: no se conoce su resultado de antemano, el conjunto de sus posibles resultados está bien determinado y se puede repetir en idénticas condiciones siempre que se quiera

\hookrightarrow suceso: acontecimiento que ocurre o no según el resultado de la prueba \hookrightarrow subconjunto de $A \subset \Omega$
 \hookrightarrow ESPACIO MUESTRAL: conjunto de resultados posibles Ω

proposiciones lógicas

- suceso imposible: $A = \emptyset$
- suceso seguro: $A = \Omega$
- sucesos incompatibles/disjuntos: $A \cap B = \emptyset$

PROBABILIDAD: $P \equiv$ probabilidad
 $\mathcal{A} \equiv$ álgebra sucesos
 $\Omega \equiv$ espacio muestral
 ↳ espacio probabilístico

$$P: \mathcal{A} \rightarrow [0,1], \quad A \in \mathcal{A} \rightarrow P(A)$$

se cumple: 1. $P(\Omega) = 1$

2. A, B disjuntos

$$P(A \cup B) = P(A) + P(B)$$

↳ aditividad

- ω , suceso elemental de Ω . $0 \leq P(\omega) \leq 1$ y $\sum_{\omega \in \Omega} P(\omega) = 1$

entonces: $P(A) = \sum_{\omega \in A} P(\omega)$

PROPIEDADES PROBABILIDAD: sucesos A, A^c disjuntos $\rightarrow A \cup A^c = \Omega$

sobre (Ω, \mathcal{A}, P)

• probabilidad suceso contrario: $P(A^c) = 1 - P(A)$

• probabilidad diferencia: $P(A - B) = P(A) - P(A \cap B)$

• probabilidad unión sucesos: $P(A \cup B) = P(A) + P(B) - P(A \cap B)$

• " 3 sucesos: $P(A_1 \cup A_2 \cup A_3) = \sum_i P(A_i) - \sum_{i,j} P(A_i \cap A_j) + P(A_1 \cap A_2 \cap A_3)$

comprobables mediante diagramas de Venn

• propiedad monotonía: $B \subset A \rightarrow P(B) \leq P(A)$

ASIGNACIÓN PROBABILIDADES

- suceso elemental: $\frac{1}{\#(\Omega)}$; $\#(\Omega) \rightarrow$ cardinal de $\Omega \rightarrow \text{card}(\Omega)$

- suceso general: $P(A) = \sum_{\omega \in A} \frac{1}{\#(\Omega)} = \frac{\#(A)}{\#(\Omega)} = \frac{n^\circ \text{ casos favorables}}{n^\circ \text{ casos posibles}}$
 ↳ regla de Laplace

- modelo equiprobable: los sucesos elementales de Ω tienen la misma probabilidad \rightarrow un dado no cargado, una moneda no cargada...

CÁLCULO POR COMPLEMENTARIO: por sucesos definidos por la condición "al menos" \rightarrow probabilidad suceso - 1

MODELOS DINAMICOS: experimentos compuestos de varios sucesos que ocurren al mismo tiempo \rightarrow cada subexperimento influye en las condiciones en que ocurre los posteriores

PROBABILIDAD CONDICIONADA: $P(B|A) = \frac{P(A \cap B)}{P(A)}$ \rightarrow suceso B tal que "si A" o "sabiendo que A"

\downarrow
P(A) es conocida y condiciona el resto de sucesos

3 propiedades
 \swarrow prob. posterior
 \searrow prob. previa

$$P(A|A) = 1$$

$$P(B^c|A) = 1 - P(B|A)$$

$$P(B_1 \cup B_2|A) = P(B_1|A) + P(B_2|A)$$

con B_1, B_2 disjuntos

- cálculo dinámico: $P(A \cap B) = P(A) P(B|A)$

- fórmula probabilidad total: $P(A) = \sum_{i=1}^n P(B_i) P(A|B_i)$ $\rightarrow B_i, B_j$ disjuntos
 \hookrightarrow fraccione el espacio muestral en B_i sucesos

- fórmula de Bayes: $P(A_j|B) = \frac{P(A_j) P(B|A_j)}{\sum_{i=1}^n P(A_i) P(B|A_i)}$ \rightarrow conocemos el resultado de un subexperimento y no se sabe el de otro subexperimento anterior

SUCESOS INDEPENDIENTES: repetir un experimento sin que el resultado influya en los restantes

- suceso A favorable a B si $P(B|A) > P(B)$: B es más frecuente cuando A ocurre

- suceso A independiente de B si $P(B|A) = P(B)$: A y B son independientes

\hookrightarrow extensible a n sucesos

\hookrightarrow también lo son sus complementarios

\downarrow \hookrightarrow contrario a ser disjuntos

$$P(A \cap B) = P(A) \cdot P(B)$$

\downarrow
extensible a experimentos independientes (lanzar una moneda y luego un dado)
componiendo los espacios muestrales $\Omega_1 \times \Omega_2$

VARIABLES ALEATORIAS: X sobre un espacio probabilístico (Ω, P) es una función $X: \Omega \rightarrow \mathbb{R}$

\hookrightarrow los sucesos elementales se asocian a la observación de la variable X

- cuando $X(\Omega)$ es finito, la variable es DISCRETA

Asignando un único valor numérico a cada $\omega \in \Omega$

↓

DISTRIBUCIÓN DE PROBABILIDAD

modo en que se reparte la probabilidad entre los posibles valores de la variable

$$P(X=x) = p(x) \quad \forall x \in X(\Omega)$$

| | |
|--------|-------|
| x | - - - |
| $p(x)$ | - - - |

$$\downarrow$$
$$\sum p(x) = 1$$

• si X es discreta,
 $Y = g(X)$, Y es discreta

↓
 $x \rightarrow p(x)$: función de probabilidad

VALOR ESPERADO: esperanza matemática, promedio de los valores que toma la variable, ponderado por el valor de su probabilidad ("centro de gravedad" de la distribución de probabilidad)

$$E(x) = \sum_{x \in X(\Omega)} x P(X=x)$$

MOMENTOS VARIABLE: son los valores esperados de las funciones potenciales de una variable y describen la forma de su distribución

$$\mu_r = E(X^r), \quad r > 0$$

o los valores esperados de las potencias de las desviaciones respecto de la media

$$g(X) = (X - E(x))^r$$

VARIANZA: mide la dispersión promedio de los valores X respecto $E(x)$, desviación respecto de la media al cuadrado

$$\sigma_x^2 = E(X - E(x))^2 = E(x^2) - E(x)^2$$

$$\sigma_{ax+b}^2 = a^2 \sigma_x^2$$

ENTROPIA: mide la incertidumbre en la distribución de la probabilidad en un conjunto. $\uparrow H$: probabilidad distribuida más uniforme

$$H(X) = - \sum_{x \in X(\Omega)} p(x) \log_2 p(x)$$

$$\log_2 x = \frac{\log x}{\log 2}$$

$$H(x) \leq 0$$

MODELOS DE DISTRIBUCIONES DISCRETAS:

- dist. Bernoulli
- dist. binomial
- dist. geométrica
- dist. Poisson


DISTRIBUCIÓN BERNOULLI: realiza UN experimento ahora que puede o no tener éxito

$$\left[\begin{array}{l} P(X=0) = 1-p \quad \text{y} \quad P(X=1) = p \\ \mu = E(X) = p \\ \sigma_x^2 = p(1-p) \end{array} \right]$$

DISTRIBUCIÓN BINOMIAL: mide el número de éxitos en las repeticiones realizadas del experimento

$$\left[\begin{array}{l} P(X=k) = \binom{n}{k} p^k (1-p)^{n-k} \\ \mu = np \quad \sigma^2 = np(1-p) \end{array} \right]$$

$$\binom{n}{k} = \frac{n!}{k!(n-k)!}$$



DIST. GEOMÉTRICA: mide el número de repeticiones hasta que se obtiene el primer éxito del experimento

$$\left[\begin{array}{l} P(X=k) = p(1-p)^{k-1} \\ \mu = E(X) = \frac{1}{p} \\ \sigma_x^2 = (1-p)/p^2 \end{array} \right]$$

éxito (uno) } hasta
K-1 fracasos


- esta distribución "carece de memoria": en una repetición no influye los resultados anteriores (siempre comienza de cero)

DIST. POISSON: mide un suceso que tiene poca probabilidad de ocurrir en un intervalo de tiempo. Depende de un parámetro $\lambda > 0$

$$P(X=k) = e^{-\lambda} \frac{\lambda^k}{k!}$$

$$\mu = E(X) = \lambda, \quad \sigma_x^2 = \lambda$$

VECTOR ALEATORIO: mide simultáneamente varias variables aleatorias en un mismo elemento, sobre un mismo espacio de probabilidad



↓
de forma similar a la función de probabilidad de una única variable

↓
función probabilidad conjunta: $p(i,j) = P(X=i, Y=j)$
 $i \in X(\Omega), j \in Y(\Omega)$

$$p(i,j) \geq 0$$

$$\sum_i \sum_j p(i,j) = 1$$

DISTRIBUCIONES MARGINALES: calculan la probabilidad de una variable aleatoria mientras la otra tome cualquier valor

↓
o distribución unidimensional

$$P(X=i) = \sum_{j \in Y(\Omega)} P(X=i, Y=j) \quad i \in X(\Omega)$$

$$P(Y=j) = \sum_{i \in X(\Omega)} P(X=i, Y=j) \quad j \in Y(\Omega)$$

- valor esperado de una dist. conjunta: $E(f(X,Y)) = \sum_i \sum_j f(i,j) P(X=i, Y=j)$

- valor esperado suma de variables: $E(X_1 + X_2) = E(X_1) + E(X_2)$

- covarianza de dos variables:
(mirar pág 79 libro)

$$\rho_{X,Y} = \frac{\sigma_{X,Y}}{\sqrt{\sigma_X^2 \sigma_Y^2}}$$

mide la variación simultánea de X e Y

- dist. condicionada: $P(X=x | Y=y) = \frac{P(X=x, Y=y)}{P(Y=y)}$ $\rightarrow P(X=x | Y) = P(X=x | Y=y_1) + \dots + P(X=x | Y=y_n)$

VARIABLES ALEATORIAS INDEPENDIENTES: ello significa que el valor de una de ellas no afecta a la distribución marginal de la otra. Propiedad simétrica

$$P(X=i, Y=j) = P(X=i) P(Y=j)$$

- extensible a dos sucesos que se distribuyen según esas variables aleatorias

$$P(X \in A, Y \in B) = P(X \in A) P(Y \in B)$$

- también a dos funciones de variables independientes: $f(x), g(y)$

- esperanza de variables independientes: $E(XY) = E(X)E(Y)$

- varianzas de la suma de variables independientes: $\sigma_{x+y}^2 = \sigma_x^2 + \sigma_y^2$

2. MODELOS PROBABILÍSTICOS CONTINUOS

FUNCIÓN DE DENSIDAD: una función que cumple las condiciones

1. $f(x) \geq 0$
 2. $\int_{-\infty}^{\infty} f(x) dx = 1$
- es función de densidad de probabilidad \neq función de probabilidad

- es una función de la distribución de la probabilidad en \mathbb{R}

- una VARIABLE ALEATORIA CONTINUA es aquella cuya distribución es sobre una función de densidad

$$P(X \in I) = \int_I f(x) dx \quad \text{o} \quad P(a < x < b) = \int_a^b f(x) dx$$

VALOR ESPERADO VARIABLE CONTINUA: es el valor esperado de una variable continua X sobre una función de densidad (promedio de los valores que toma y la probabilidad en esos valores)

$$E(X) = \int_{-\infty}^{\infty} x f(x) dx$$

↓
si $E(X) = \infty$, la variable no tiene valor medio

VARIANZA DE UNA VARIABLE CONTINUA:

$$\sigma_x^2 = \underbrace{\int_{-\infty}^{\infty} x^2 f(x) dx}_{E(x^2)} - E(x)^2$$

MODELOS FUNCIONES DENSIDAD:


- función densidad uniforme
- función densidad exponencial
- función densidad normal

FUNCION DENSIDAD UNIFORME: elige un punto al azar en un intervalo $[a, b]$ con $a < b$

$$E(x) = \frac{a+b}{2}$$

$$\sigma_x^2 = \frac{1}{12} (b-a)^2$$


$$f(x) = \begin{cases} \frac{1}{b-a} & , \text{ si } x \in [a, b] \\ 0 & , \text{ resto} \end{cases}$$



es una función constante en el intervalo

FUNCION DENSIDAD EXPONENCIAL: depende de un $\lambda > 0$ que hace disminuir la función cuanto más alto sea

$$E(x) = \frac{1}{\lambda} ; \sigma_x^2 = \frac{1}{\lambda^2}$$



$$f(x) = \begin{cases} 0 & , \text{ si } x < 0 \\ \lambda e^{-\lambda x} & , \text{ si } x \geq 0 \end{cases}$$

son similares a la dist. geométrica y "carecen de memoria"

FUNCION DENSIDAD NORMAL: depende de 2 parámetros μ y σ donde


$\mu \rightarrow$ media distribución

$\sigma^2 \rightarrow$ varianza distribución

$$f(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}$$

↓

$X \sim N(0,1)$: simétrica y tabulada



$$f(x) = \frac{1}{\sqrt{2\pi} \sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

$$-\infty < x < \infty$$

↓

$X \sim N(\mu, \sigma) \rightarrow X$ tiene una distribución normal de parámetros μ, σ

- transformación lineal de una variable normal: $E(ax+b) = a \overbrace{E(x)}^{\mu} + b = a\mu + b$
 $\sigma_{ax+b}^2 = \sigma_{ax}^2 = a^2 \sigma^2$

CÁLCULOS CON LA DENSIDAD NORMAL: cuando $X \sim N(\mu, \sigma)$, la transformación $X \rightarrow \frac{X-\mu}{\sigma} = Z$ tiene distribución $N(0,1)$

$$P(N(\mu, \sigma) > x) = P(N(0,1) > z)$$

↓

$$z = \frac{x-\mu}{\sigma}$$

↳ tipificando de X ejemplo p. 112

$$- P(z < -z) = P(z > z), z > 0$$

$$- P(z > z) = P(z > z) \rightarrow \text{valores tabulados}$$

$$- P(z \leq z) = P(z < z) \quad N(0,1)$$

$$\hookrightarrow 1 - P(z > z)$$

$$- P(0 < x < a) = P(x > 0) - P(x > a)$$

$$- P(b < x < a) = P(x > b) - P(x > a)$$

$$- P(-b < x < a) = 1 - P(x > b) - P(x > a)$$

↳ cálculo por complementario

guíase por gráfica también

FUNCIÓN DE DISTRIBUCIÓN: en cada punto, devuelve la probabilidad de que la variable tome valores menores o iguales al de ese punto

↓
describe cómo se reparte la probabilidad entre los valores de X

$$F(x) = P(X \leq x), x \in \mathbb{R}$$

3 condiciones: 1. F no decreciente: $x < x'$,

$$F(x) < F(x')$$

2. F continua por la derecha

$$3. \lim_{x \rightarrow \infty} F(x) = 1 \quad \text{y} \quad \lim_{x \rightarrow -\infty} F(x) = 0$$

- puede tener intervalos no disjuntos, todo los puntos en X tienen valor en $F(x)$

$$- [a, b] : F(b) - F(a^-) = P(a \leq x \leq b)$$

$$- (a, b) : F(b^-) - F(a) = P(a < x < b)$$

$$- [a, b) : F(b^-) - F(a^-) = P(a \leq x < b)$$

$$- P(X=a) = P(X \leq a) - P(X < a) = F(a) - F(a^-)$$

↳ prob. acumulada en un punto

p. 116

→ especialmente en funciones de distribución de variables discretas

- en una función de distribución de una variable discreta hay tantos saltos como valores de X y el tamaño de los saltos es la probabilidad concentrada en esos puntos (fuera de los saltos no hay probabilidad en el intervalo)
- en una función de distribución de una variable continua se tiene que:

$$F(x) = P(X \leq x) = \int_{-\infty}^x f(x) dx$$

↓

si $\int_{-\infty}^{\infty} F'(x) dx = 1$ entonces X es variable aleatoria continua

FUNCION DENSIDAD CONJUNTA: se define sobre un vector aleatorio (X, Y) con una distribución de probabilidad continua $f(x, y)$

$$P(X \in I_1, Y \in I_2) = \iint_{I_1 \times I_2} f(x, y) dx dy$$

- $f(x, y)$ es función densidad conjunta si: $\iint f(x, y) dy dx = 1$

$$f(x, y) \geq 0 \text{ para } -\infty < x < \infty, -\infty < y < \infty$$

- funciones densidad marginales:

$$\begin{aligned} f_x(x) &= \int_{-\infty}^{\infty} f(x, y) dy \\ f_y(y) &= \int_{-\infty}^{\infty} f(x, y) dx \end{aligned}$$

→ x fijo, y variable

- funciones densidad condicionadas:

↓

modelo dinámico:

$$\begin{aligned} f(x, y) &= f_x(x) f(y|x) = \\ &= f_y(y) f(x|y) \end{aligned}$$

$$\begin{aligned} f_{y|x}(y) &= \begin{cases} \frac{f(x, y)}{f_x(x)}, & \text{si } f_x(x) > 0 \\ 0, & \text{si } f_x(x) = 0 \end{cases} \\ f_{x|y}(x) &= \begin{cases} \frac{f(x, y)}{f_y(y)}, & \text{si } f_y(y) > 0 \\ 0, & \text{si } f_y(y) = 0 \end{cases} \end{aligned}$$

- independencia de variables: $f(x,y) = f_x(x) f_y(y)$ para cada (x,y)
 ↳ solo hay independencia en recintos rectangulares
- valores esperados: $E(x) = \int_{-\infty}^{\infty} x f_x(x) dx$; $E(y) = \int_{-\infty}^{\infty} y f_y(y) dy$

3. MUESTREO ALEATORIO

INFERENCIA ESTADÍSTICA: a partir de observaciones repetidas de un fenómeno aleatorio se puede reducir la incertidumbre en algún aspecto de la distribución de probabilidad que lo rigen y tomarlo como verdadero por su estudio

↓
 hace análisis y elabora previsiones en base a funciones calculadas a partir de los datos muestrales

↳ MUESTRAS: datos obtenidos de la observación

↳ DIST. POBLACION: distrib. de la variable observable

MUESTRA ALEATORIA SIMPLE: son las observaciones realizadas de una variable aleatoria $X = (x_1, x_2, \dots, x_n) \rightarrow n$: tamaño de la muestra

↓
 ESTADÍSTICO: función de los valores muestrales

DISTRIBUCIÓN MUESTRAL: distribución de la probabilidad de los resultados posibles del muestreo realizado

- si X discreta: $p(x_1, x_2, \dots, x_n) = p(x_1) p(x_2) \dots p(x_n)$

- si X continua: $f(x_1, x_2, \dots, x_n) = f(x_1) f(x_2) \dots f(x_n)$

- cuanto mayor es n , el estadístico media muestral nos se aproxima a la media de la distribución

$$X \sim \text{dist.}(\mu, \sigma) \Rightarrow \bar{X} \sim \text{dist.}\left(\mu, \frac{\sigma^2}{n}\right)$$

DISTRIBUCIONES PROPIAS DEL MUESTREO: - dist. χ^2 Pearson
(generalmente en poblaciones normales) - dist. t Student

DIST. χ^2 PEARSON: sobre una población teórica $N(0,1)$, una var. aleatoria discreta X de tamaño n la muestra, la suma de cuadrados $Y = \sum x_i^2$ tiene una distribución χ^2 con n grados de libertad ($n =$ sumandos que aportan variabilidad)

$$E(Y) = n \quad \sigma_Y^2 = 2n$$

- si X tiene una distribución $N(0, \sigma)$: $X \sim N(0, \sigma)$, el estadístico

$$\frac{1}{\sigma^2} \sum_{i=1}^n x_i^2 \text{ tiene una dist. } \chi_n^2$$

s^2 y \bar{X} son independientes y

tiene una dist. χ_{n-1}^2

\downarrow
n-1 grados libertad


$$\begin{aligned} \bar{X} &= \frac{1}{n} \sum x_i \\ s^2 &= \frac{1}{n} \sum x_i^2 - \bar{X}^2 \\ s^2 &= \frac{1}{n-1} s^2 \end{aligned}$$

media muestral

varianza muestral

covarianza

- la dist. χ^2 tiene valores tabulados por distintos grados de libertad \downarrow tabla y valores de probabilidad \rightarrow tabla




DIST. t STUDENT: sobre una muestra aleatoria simple (X_1, X_2, \dots, X_n) de una población $N(\mu, \sigma)$, el estadístico t Student:

$$t = \sqrt{n-1} \frac{\bar{X} - \mu}{s}$$

tiene dist. t Student con

$(n-1)$ grados de libertad



\hookrightarrow como es simétrica respecto origen, tiene mismas propiedades de cálculo de $N(0,1)$

4. INFERENCIA ESTADÍSTICA

ESTIMACIONES POR PUNTO: un estimador puntual es un estadístico función de las observaciones muestrales de una variable aleatoria simple X que permite tomar decisiones sobre el parámetro deseado de la distribución

$$\theta : \hat{\theta} = T(X_1, X_2, \dots, X_n)$$

$\hat{\theta}$ = valor estimado de θ

- lo más deseable a un estimador es que su valor esperado coincida con el parámetro a estimar: $E(\hat{\theta}) = \theta$
- la diferencia entre ellos se denomina SESGO: $b = E(\hat{\theta}) - \theta$

ESTIMADOR CENTRADO: es aquel en que el sesgo es 0

↳ 0 sesgado

2 estimadores insesgados: media muestral y covarianza muestral

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i^2 \quad S^2 = \frac{1}{n-1} \left(\sum_{i=1}^n X_i^2 - n \bar{X}^2 \right)$$

1 estimador sesgado: varianza muestral $\hat{s}^2 \rightarrow \sigma^2$

$$s^2 = \frac{1}{n} \left(\sum_{i=1}^n X_i^2 \right) - \bar{X}^2 \quad \text{con sesgo} = -\sigma^2/n$$

ESTIMADOR SUFICIENTE: un estimador es suficiente para la estimación de un parámetro si la dist. de la muestra condicionada por el estimador es independiente del parámetro

ESTIMADOR MÁXIMA VEROSIMILITUD: dada una función de densidad de una muestra

$f(x_1, \dots, x_n; \hat{\theta}) = \max_{\theta} f(x_1, \dots, x_n; \theta)$ el estimador $\hat{\theta}$ es de máxima verosimilitud si f alcanza su máximo cuando $\theta = \hat{\theta}$


- el principio de máx. verosimilitud establece que la aparición de un suceso atribuido a un modelo entre los modelos probabilísticos del fenómeno hace máxima la probabilidad de que ocurra el suceso
- es aplicable a cualquier aplicación biyectiva de la función de este

INTERVALOS DE CONFIANZA: la estimación por intervalos de confianza consiste en encontrar un intervalo en el que con una probabilidad estimada, se encuentre el estadístico θ a partir del $\hat{\theta}$ obtenido en el muestreo

márgenes de variación ← alrededor de $\hat{\theta}$ donde θ se encuentra

- Dado un nivel de confianza se encuentra un valor z tal que:

$$P(-z_\alpha < \theta < z_\alpha) = \alpha$$



- a mayor amplitud intervalo, mayor imprecisión
- α, n (tamaño muestra) fijos: mayor σ , mayor amplitud
- σ, n fijos: $\uparrow \alpha \rightarrow \uparrow$ amplitud
- α, σ fijos: $\uparrow n \rightarrow \uparrow$ amplitud

- Método de la cantidad pivotal: consiste en, mediante transformaciones de las observaciones del intervalo, hacer que el intervalo de confianza no se centre en $T(x_1, \dots, x_n; \theta)$ sino en una función del propio θ ($g(\theta)$) con nivel de confianza α

$$P(c_1 \leq T(x_1, \dots, x_n; \theta) \leq c_2) \geq \alpha$$


↓

$$P(g(x_1, \dots, x_n; c_1) \leq g(\theta) \leq g(x_1, \dots, x_n; c_2)) \geq \alpha$$

INTERVALOS DE CONFIANZA EN DISTRIBUCIONES NORMALES: para poblaciones

$N(\mu, \sigma)$ y (X_1, \dots, X_n)

- con σ conocida:
por la media μ



$$\left(\bar{X} - z_{\alpha/2} \frac{\sigma}{\sqrt{n}}, \bar{X} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}} \right)$$


con $P(Z > z_{\alpha}) = \frac{\alpha}{2}$

↑ el intervalo se
centra en μ

$Z \sim N(0, 1)$

$z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}}$

- con σ desconocida:
por la media μ



$$\left(\bar{X} - t_{n-1, \alpha/2} \frac{S}{\sqrt{n}}, \bar{X} + t_{n-1, \alpha/2} \frac{S}{\sqrt{n}} \right)$$

con $P(t_{n-1} > t_{n-1, \alpha}) = \frac{\alpha}{2}$


↑ el intervalo queda
centrado en μ

$t = \frac{\bar{X} - \mu}{S/\sqrt{n}}$

$S^2 \equiv$ covarianza
muestra

con μ también desconocida

- intervalo por σ :



$$\left(\frac{n s^2}{\chi^2_{n-1, \alpha/2}}, \frac{n s^2}{\chi^2_{n-1, 1-\alpha/2}} \right)$$

con $P(\chi^2 > \chi^2_{n-1, 1-\alpha/2}) = 1 - \frac{\alpha}{2}$

y $P(\chi^2 > \chi^2_{n-1, \alpha/2}) = \frac{\alpha}{2}$

↓ intervalo centrado en σ

CONTRASTE DE HIPÓTESIS: son técnicas de inferencia que buscan descartar

conjeturas acerca de un modelo probabilístico a partir de la información obtenida por la muestra

generalmente:

$H_0: \theta \in \Theta_0$

$H_1: \theta \in \Theta_1$

Θ_0, Θ_1 disjuntos

↳ H_0 : hipótesis nula → hipótesis de partida

↳ H_1 : hipótesis alternativa → cuando H_0 se rechaza

- por el contraste de hipótesis se realizan pruebas, tests
- la REGIÓN CRÍTICA de un test es el conjunto de muestras que llevan a rechazar $H_0 \rightarrow$ la REGIÓN de ACEPTACIÓN llevan a aceptar H_0
- como consecuencia de la decisión en el test de hipótesis se pueden dar

2 errores:

1. Error tipo I $\rightarrow ET1 = P(\text{rechazar } H_0 \mid H_0 \text{ cierta})$

2. Error tipo II $\rightarrow ET2 = P(\text{no rechazar } H_0 \mid H_0 \text{ falsa})$

\downarrow
 en el diseño de tests se fija, en función de hipótesis, un coh de probabilidad para cometer ET1 $\rightarrow \alpha$

\hookrightarrow entre los tests que $ET1 < \alpha$, el test que hace ET2 mínima

- la POTENCIA DEL TEST es la probabilidad de rechazar H_0 cuando el valor de θ es θ_1 :

$$\beta(\theta_1) = 1 - ET2 = P(C \mid \theta = \theta_1)$$

CONTRASTES DE HIPÓTESIS UNILATERALES: 4 casos

- | | |
|--|---|
| 1. $H_0: \theta = \theta_0$ frente $H_1: \theta > \theta_0$ | } con $N(\mu, \sigma)$, RC está definida por $\bar{X} > c$ |
| 2. $H_0: \theta \leq \theta_0$ frente $H_1: \theta > \theta_0$ | |
| 3. $H_0: \theta = \theta_0$ frente $H_1: \theta < \theta_0$ | } con $N(\mu, \sigma)$, RC está definida por $\bar{X} < c$ |
| 4. $H_0: \theta \geq \theta_0$ frente $H_1: \theta < \theta_0$ | |

CONTRASTE HIPÓTESIS BILATERALES: 1 caso

5. $H_0: \theta = \theta_0$ frente $H_1: \theta \neq \theta_0 \rightarrow$ con $N(\mu, \sigma)$, RC definida sobre $|\bar{X}| \geq c$

contrastes paramétricos

CONTRASTE DE BONIDAD DEL AJUSTE: verifican si la distribución de la población se reparte ajustado a un patrón permitiendo rechazar la hipótesis que suponga que los datos siguen una distribución determinada

comparando la frecuencia observada con la teórica

↳ H_0 : probabilidades teóricas

↓
valor discrepancia de Pearson:

$$D = n \left(-1 + \sum_{i=1}^n \frac{\hat{p}_i^2}{p_i} \right)$$

\hat{p}_i = prob. prácticas (muestra)

p_i = prob. teóricas

$D > 0$ siempre //

H_0 rechazada si

$D > d^*$ (nivel crítico según nivel significación, α)

↓
se distribuye como χ^2 con $n-1$ grados de libertad

5. MODELOS DE OPTIMIZACIÓN

MODELO MATEMÁTICO DE OPTIMIZACIÓN: es una representación matemática de un sistema real con 3 elementos

- **VARIABLES:** representan las alternativas del sistema. Son n.º reales
- **RESTRICCIONES:** igualdades o desigualdades que ligam las variables y representan las relaciones y condiciones del sistema
- **FUNCIÓN OBJETIVO:** permite comparar alternativas en el conjunto de valores de las variables cumpliendo las condiciones del sistema.
↳ debe ser única con el objetivo de maximizar o minimizar el problema
- las variables pueden ser o no controlables según se tomen dentro de las limitaciones del modelo o versen implícitas de hacer

- las restricciones relacionan las variables, constantes y parámetros del modelo
 ↳ pueden venir en la definición del modelo, empíricas, normativas (según el entorno del modelo) ...
- los datos a analizar han de ser cuantitativos

PROBLEMA DE OPTIMIZACIÓN: consiste en optimizar (encontrar el máximo o el mínimo) de una serie de funciones con n variables y sujeta al cumplimiento de unas restricciones

$$\left. \begin{array}{l} \text{Optimizar } f(x_1, x_2, \dots, x_n) \\ \text{sujeto a } g_i(x_1, x_2, \dots, x_n) \geq 0 \quad i=1, \dots, m \\ h_j(x_1, x_2, \dots, x_n) = 0 \quad j=1, \dots, p \end{array} \right\} \rightarrow \text{si las funciones son lineales:}$$

PPL \rightarrow problema de programación lineal

FORMA GENERAL PPL:

$$\left. \begin{array}{l} \text{Optimizar } z = C_1 x_1 + \dots + C_n x_n \\ \text{sujeto a } a_{11} x_1 + \dots + a_{1n} x_n \leq b_1 \\ \vdots \\ a_{p1} x_1 + \dots + a_{pn} x_n = b_p \end{array} \right\} \rightarrow \begin{array}{l} x_i \equiv \text{variables de decisión} \\ a_{ij} \equiv \text{coeficientes tecnológicos} \\ \equiv \text{restricciones} \end{array}$$

$x_1, \dots, x_q \geq 0$ \rightarrow \equiv restricciones no negativas

x_{q+1}, \dots, x_n cualesquiera

$b_i \equiv$ vector de disponibilidades

$C_i \equiv$ coeficientes de beneficio / costo

$z \equiv$ función objetivo

↓
 por poder hacer el PPL se realizan formulaciones equivalentes del problema

- un problema de maximización se convierte en uno de minimización y viceversa

$$\text{máximo } \sum_i C_i x_i = - \text{mínimo } \sum_i C_i x_i$$

- las variables x_i no pueden ser negativas. Si x_i puede tomar cualquier valor,

se descompone en: $x_i = x_i^+ - x_i^-$ con $x_i^+ = \max \{0, x_i\} \geq 0$
 $x_i^- = \max \{0, -x_i\} \geq 0$

- las ecuaciones se pueden pasar a inecuaciones:

$$a_1 x_1 + \dots + a_n x_n = b_i \rightarrow a_1 x_1 + \dots + a_n x_n \leq b_i$$

$$a_1 x_1 + \dots + a_n x_n \geq b_i \rightarrow -a_1 x_1 - \dots - a_n x_n \leq -b_i$$

- las inecuaciones se pueden convertir en igualdades incluyendo una variable de holgura
 modo VARIABLE DE HOLGURA

$$a_1 x_1 + \dots + a_n x_n \leq b_i \rightarrow a_1 x_1 + \dots + a_n x_n + s_i = b_i$$

$$a_1 x_1 + \dots + a_n x_n \geq b_i \rightarrow a_1 x_1 + \dots + a_n x_n - s_i = b_i$$

FORMA CANONICA PPL:

maximizar: $z = C_1 x_1 + \dots + C_n x_n$

sujeto a: $a_1 x_1 + \dots + a_n x_n \leq b_1$

\vdots

$a_m x_1 + \dots + a_n x_n \leq b_m$

$x_1, \dots, x_n \geq 0$

FORMA STANDARD PPL:

maximizar: $z = C_1 x_1 + \dots + C_n x_n$

sujeto a: $a_1 x_1 + \dots + a_n x_n = b_1$

\vdots

$a_m x_1 + \dots + a_n x_n = b_m$

$x_1, \dots, x_n \geq 0$

- los modelos a su vez pueden expresarse en forma matricial:

maximizar: $z = Cx$

sujeto a: $\Delta x \leq b$

$x \geq 0$

maximizar: $z = Cx$

sujeto a: $\Delta x = b$

$x \geq 0$

$\Delta = \begin{pmatrix} a_{11} & \dots & a_{1n} \\ \vdots & & \vdots \\ a_{m1} & \dots & a_{mn} \end{pmatrix}$; $c = (c_1, \dots, c_n)$; $b = \begin{pmatrix} b_1 \\ \vdots \\ b_m \end{pmatrix}$; $x = \begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix}$

- el PROGRAMA o SOLUCIÓN FACTIBLE del PPL son los valores de x que satisfacen las restricciones del problema \rightarrow todas las variables son ≥ 0

\hookrightarrow su conjunto es la REGIÓN FACTIBLE \downarrow es un polígono convexo con los puntos del mismo

- Los VERTICES son puntos de la región factible que corresponden con los valores de un programa básico

\rightarrow una ARISTAS

- las soluciones factibles que están sobre una arista forman la FRONTERA y las de dentro de la región factible, INTERIOR

- el PROGRAMA ÓPTIMO es el programa de PPL que hace que la función objetivo alcance su valor máximo

\hookrightarrow REGIÓN ÓPTIMA

\hookrightarrow VALOR ÓPTIMO: el de la función objetivo en un programa óptimo

- si un PPL tiene más de un programa óptimo, tiene infinitas soluciones óptimas

- si la región factible no está acotada puede suceder:

\hookrightarrow tiene un valor óptimo infinito

\hookrightarrow " " finito

- la región factible puede quedar vacía \rightarrow el PPL es no factible y no tiene solución óptima cualquiera sea la función objetivo